

Contents

1	Introduction	2
2	Théorème de Bayes	2
3	Principe de la classification bayésienne	2
4	Classificateur Naïve Bayes	2
4.1	Hypothèse d'indépendance	2
4.2	Types de classificateurs Naïve Bayes	2
5	Étapes de la classification bayésienne	2
6	Exemple de classification	3
7	Avantages et inconvénients	3
7.1	Avantages	3
7.2	Inconvénients	3
8	Applications	3
9	Naive Bayes Multinomial	3
9.1	The distribution of Words in spam and non spam messages	4
9.2	Cleaned distribution of words in spam and non spam	4
9.3	Features engineering	5
9.4	Training the multinomial naive bayes	5
9.5	Predictive Analysis	5
9.5.1	Multinomial naive bayes classifier	5
9.5.2	Confusion Matrix	6
10	Gaussian Naive Bayes	6
10.0.1	Iris Gaussian Distribution	6
10.0.2	Applying PCA	8
11	Conclusion	9
12	Références	10

1 Introduction

La classification bayésienne est une méthode statistique de classification fondée sur la **théorie des probabilités** et plus précisément sur le **théorème de Bayes**. Elle permet d'attribuer une observation à une classe en calculant la probabilité que cette observation appartienne à chaque classe possible.

Cette approche est largement utilisée en apprentissage automatique, en fouille de données, en reconnaissance de formes, en diagnostic médical, en filtrage de courriels indésirables (spam) et en télédétection. Sa popularité provient de sa simplicité, de sa rapidité et de sa base mathématique solide.

2 Théorème de Bayes

Le théorème de Bayes est donné par la formule suivante :

$$P(C | X) = \frac{P(X | C)P(C)}{P(X)} \quad (1)$$

avec :

- $P(C | X)$: probabilité a posteriori de la classe C sachant l'observation X
- $P(X | C)$: vraisemblance, probabilité d'observer X si la classe C est vraie
- $P(C)$: probabilité a priori de la classe C
- $P(X)$: probabilité d'observer X

Dans les problèmes de classification, $P(X)$ est identique pour toutes les classes et peut donc être ignorée lors de la comparaison (constant de normalisation).

3 Principe de la classification bayésienne

Le principe de la classification bayésienne consiste à :

1. Calculer la probabilité a posteriori pour chaque classe
2. Comparer ces probabilités
3. Attribuer l'observation à la classe ayant la probabilité maximale

Mathématiquement, la règle de décision s'écrit :

$$Classe(X) = \arg \max_C [P(X | C)P(C)] \quad (2)$$

4 Classificateur Naïve Bayes

4.1 Hypothèse d'indépendance

Le classificateur Naïve Bayes repose sur une hypothèse simplificatrice forte : les variables descriptives sont **conditionnellement indépendantes** sachant la classe.

$$P(X | C) = \prod_{i=1}^n P(x_i | C) \quad (3)$$

Bien que cette hypothèse soit rarement vérifiée dans la réalité, le classificateur Naïve Bayes donne souvent de très bons résultats en pratique.

4.2 Types de classificateurs Naïve Bayes

- **Naïve Bayes Gaussien** : utilisé pour des variables continues
- **Naïve Bayes Multinomial** : utilisé principalement pour la classification de textes
- **Naïve Bayes Bernoulli** : utilisé pour des variables binaires

5 Étapes de la classification bayésienne

Les principales étapes sont :

1. Collecte et prétraitement des données
2. Estimation des probabilités a priori $P(C)$
3. Estimation des vraisemblances $P(X | C)$
4. Calcul des probabilités a posteriori
5. Attribution de la classe ayant la probabilité maximale

6 Exemple de classification

Considérons un exemple simple de filtrage de courriels. On souhaite classer un email comme *Spam* ou *Non-Spam*.

Probabilités a priori :

- $P(\textit{Spam}) = 0.4$
- $P(\textit{Non-Spam}) = 0.6$

Vraisemblances :

- $P(\text{“free”} \mid \textit{Spam}) = 0.8$
- $P(\text{“free”} \mid \textit{Non-Spam}) = 0.1$

Calcul des probabilités proportionnelles :

$$P(\textit{Spam} \mid \textit{free}) \propto 0.8 \times 0.4 = 0.32 \quad (4)$$

$$P(\textit{Non-Spam} \mid \textit{free}) \propto 0.1 \times 0.6 = 0.06 \quad (5)$$

L’email est donc classé comme **Spam**.

7 Avantages et inconvénients

7.1 Avantages

- Méthode simple et rapide
- Efficace avec de petits jeux de données
- Capable de gérer les données manquantes
- Solide fondement théorique

7.2 Inconvénients

- Hypothèse d’indépendance souvent irréaliste
- Performances réduites lorsque les variables sont fortement corrélées

8 Applications

La classification bayésienne est utilisée dans de nombreux domaines :

- Détection de spam
- Diagnostic médical
- Classification de textes
- Reconnaissance d’images et de formes
- Télédétection et classification de l’occupation du sol

9 Naive Bayes Multinomial

Le classifieur **Naive Bayes Multinomial** est une extension du modèle de Bernoulli. Alors que le modèle de Bernoulli ne considère que la présence ou l’absence d’un mot dans un texte, le modèle multinomial prend en compte **le nombre de répétitions de chaque mot**, ce qui le rend plus adapté et plus précis pour les tâches de classification de textes.

Dans cette section, nous utilisons le jeu de données **SMS Spam Collection** disponible sur **Kaggle**¹. Ce jeu de données contient des messages SMS étiquetés comme *spam* ou *non-spam (ham)*.

La figure suivante illustre la distribution des probabilités a priori des deux classes. On observe un fort déséquilibre :

$$P(\textit{spam}) = 0.134 \quad \text{et} \quad P(\textit{non-spam}) = 0.866$$

¹ Almeida, T. & Hidalgo, J. (2011). SMS Spam Collection Dataset. Kaggle




Figure 1: Distribution des classes spam et non-spam

9.1 The distribution of Words in spam and non spam messages

Cette partie présente la fréquence des mots les plus courants dans les messages spam et non-spam. On remarque la présence massive de **stop words** (tels que *to*, *you*, *the*), qui n'apportent que peu d'information discriminante pour la classification.

Afin de faciliter la comparaison, les deux distributions sont présentées dans une même figure.




Figure 2: Distribution brute des mots dans les messages spam et non-spam

9.2 Cleaned distribution of words in spam and non spam

Après suppression des **stop words**, seules les expressions réellement informatives sont conservées. Cette étape permet de mettre en évidence les mots caractéristiques des messages spam (par exemple : *free*, *win*, *call*) et des messages non-spam.

La figure ci-dessous présente les **5 mots les plus fréquents** pour chaque classe après nettoyage.




Figure 3: Distribution des mots après suppression des stop words

9.3 Features engineering

L'ingénierie des caractéristiques comprend :

- le prétraitement du texte,
- la tokenisation,
- la suppression des stop words,
- la transformation des documents en vecteurs de caractéristiques.

Cette étape est essentielle afin d'améliorer la qualité analytique du modèle. **La suppression des stop words permet de réduire le bruit et d'augmenter la performance du classifieur.**

9.4 Training the multinomial naive bayes

Objectif principal : prédire si un nouveau SMS est un spam ou un non-spam.

Cependant, toutes les erreurs n'ont pas le même impact. Nous considérons qu'il est **bien plus grave de classer un message non-spam comme spam (faux positif)** que l'inverse.

- **Faux négatif** (spam classé comme non-spam) : le message apparaît dans la boîte de réception et peut être supprimé.
- **Faux positif** (non-spam classé comme spam) : le message est placé dans le dossier spam et risque de ne jamais être lu.

Nous privilégions donc la précision (precision) plutôt que le rappel.

9.5 Predictive Analysis

La variable cible est transformée en variable binaire :

$$\text{spam} = 1, \quad \text{non-spam} = 0$$

Le jeu de données est ensuite divisé en un ensemble d'entraînement et un ensemble de test (67% / 33%).

9.5.1 Multinomial naive bayes classifier

Un balayage du paramètre de lissage α est effectué afin d'optimiser les performances du modèle. Pour chaque valeur de α , les métriques suivantes sont calculées :

- exactitude (accuracy),
- rappel (recall),
- précision (precision).

Table 1: Extrait des performances pour différentes valeurs de α

α	Accuracy (Train)	Accuracy (Test)	Recall	Precision
0.00001	0.9987	0.9744	0.9206	0.8958
0.22001	0.9979	0.9772	0.9365	0.9008
0.99001	0.9960	0.9761	0.9206	0.9063

Le modèle sélectionné est celui qui maximise la **précision sur le jeu de test**.

Table 2: Meilleur modèle sélectionné

Paramètre	Valeur
α	15.73
Accuracy (Test)	0.9695
Recall (Test)	0.7778
Precision (Test)	1.0000

9.5.2 Confusion Matrix

La matrice de confusion du modèle final est présentée ci-dessous :

Table 3: Matrice de confusion Multinomial Naive Bayes

	Prédit non-spam	Prédit spam
Non-spam réel	1587	0
Spam réel	56	196

Analyse finale Le modèle final atteint une **précision de 100%**, ce qui signifie qu'aucun message non-spam n'a été classé comme spam. Bien que le rappel soit plus faible, ce compromis est volontaire et cohérent avec l'objectif initial : **éviter absolument les faux positifs**.

10 Gaussian Naive Bayes

Le classifieur **Gaussian Naive Bayes** est généralement utilisé pour la classification de variables continues. Dans cette section, nous appliquons ce modèle au **jeu de données Iris**, en ne considérant que deux classes : **setosa** et **versicolor**.

Les variables explicatives X utilisées sont les quatre caractéristiques morphologiques suivantes :

- longueur du sépale (*sepal length*),
- largeur du sépale (*sepal width*),
- longueur du pétale (*petal length*),
- largeur du pétale (*petal width*).

Les probabilités a priori des deux classes sont supposées égales :

$$P(\text{setosa}) = P(\text{versicolor}) = 0.5$$

10.0.1 Iris Gaussian Distribution

Dans cette partie, nous analysons la distribution gaussienne de chaque variable explicative pour les deux classes. Pour chaque caractéristique X_i et chaque classe C , nous estimons :

- la moyenne empirique $\mu_{i,C}$,
- la variance empirique $\sigma_{i,C}^2$.

Ces paramètres permettent de modéliser la vraisemblance conditionnelle $P(X_i | C)$ à l'aide d'une loi normale.




Figure 4: Distribution gaussienne théorique des variables de l'Iris

Exemple illustratif du calcul de vraisemblance :




Figure 5: Exemple de calcul des vraisemblances pour Gaussian Naive Bayes

Analyse pour l'observation d'indice 55 Classe réelle : versicolor

Valeurs observées :

sepal length = 5.7,
sepal width = 2.8,
petal length = 4.5,
petal width = 1.3

Calcul des probabilités Classe *setosa*

- A priori : $P(\text{setosa}) = 0.5$
- Vraisemblances :

$$P(x_1 | \text{setosa}) = 0.1629$$

$$P(x_2 | \text{setosa}) = 0.2668$$

$$P(x_3 | \text{setosa}) = 0.0000$$

$$P(x_4 | \text{setosa}) = 0.0000$$

- Vraisemblance totale :

$$P(x | \text{setosa}) = 2.54 \times 10^{-89}$$

- Postérieur non normalisé :

$$P(\text{setosa} | x) \propto 1.27 \times 10^{-89}$$

Calcul des probabilités Classe *versicolor*

- A priori : $P(\text{versicolor}) = 0.5$
- Vraisemblances :

$$P(x_1 | \text{versicolor}) = 0.6962$$

$$P(x_2 | \text{versicolor}) = 1.2655$$

$$P(x_3 | \text{versicolor}) = 0.7452$$

$$P(x_4 | \text{versicolor}) = 2.0000$$

- Vraisemblance totale :

$$P(x | \text{versicolor}) = 1.3131$$

- Postérieur non normalisé :

$$P(\text{versicolor} | x) \propto 0.6565$$

Classe prédite : *versicolor* (classification correcte)

10.0.2 Applying PCA

Afin de réduire la dimensionnalité des données, nous appliquons une **Analyse en Composantes Principales (PCA)** sur les variables explicatives. Toutes les variables X sont projetées sur une seule composante principale.

La distribution gaussienne de cette composante est illustrée ci-dessous :




Figure 6: Distribution gaussienne après réduction PCA

Après l'application de la PCA, une séparation plus nette entre les deux classes est observée, ce qui facilite grandement la classification.




Figure 7: Séparation des classes après PCA

Évaluation du modèle après PCA Le classifieur **Gaussian Naive Bayes** est entraîné sur la composante PCA. Une validation croisée à 5 plis est utilisée pour optimiser le paramètre `var_smoothing`.

Meilleur paramètre obtenu :

$$\text{var_smoothing} = 10^{-9}$$

Précision moyenne en validation croisée : 1.00

Table 4: Performances du modèle GaussianNB après PCA

Classe	Précision	Rappel	F1-score	Support
Setosa	1.00	1.00	1.00	15
Versicolor	1.00	1.00	1.00	15
Exactitude globale	1.00			

Précision finale sur la classe versicolor : 1.0000

11 Conclusion

La classification bayésienne constitue une approche probabiliste à la fois puissante, efficace et largement adoptée pour résoudre des problèmes de classification en apprentissage automatique. En s'appuyant sur le théorème de Bayes et sur l'hypothèse d'indépendance conditionnelle entre les variables explicatives, les classificateurs Naïve Bayes offrent un excellent compromis entre simplicité théorique et performance pratique.

Malgré le caractère souvent irréaliste de l'hypothèse d'indépendance, les résultats obtenus dans ce travail montrent que les modèles Bernoulli, Multinomial et Gaussien restent très performants lorsqu'ils sont correctement adaptés à la nature des données. Le modèle Bernoulli est particulièrement adapté aux variables binaires, le modèle Multinomial s'avère très efficace pour la classification de textes, notamment dans la détection de spam, tandis que le modèle Gaussien est bien approprié aux variables continues, comme illustré avec le jeu de données Iris.

L'intégration de techniques complémentaires, telles que l'ingénierie des caractéristiques et la réduction de dimension par Analyse en Composantes Principales (PCA), permet d'améliorer significativement la séparabilité des classes et les performances globales des modèles. De plus, l'optimisation des hyperparamètres et l'utilisation de métriques adaptées au contexte applicatif, en particulier la précision dans les problèmes sensibles aux faux positifs, se révèlent essentielles pour répondre à des objectifs concrets et réalistes.

En conclusion, le classificateur Naïve Bayes demeure un outil fondamental en apprentissage automatique, apprécié pour sa rapidité, sa faible complexité computationnelle et sa robustesse. Il constitue souvent une solution de référence ou un point de départ pertinent avant l'utilisation de modèles plus complexes, tout en restant, dans de nombreux cas, une approche suffisante et efficace pour des applications réelles.

12 Références

- Duda, R. O., Hart, P. E., Stork, D. G., *Pattern Classification*
- Bishop, C. M., *Pattern Recognition and Machine Learning*
- Mitchell, T., *Machine Learning*