

Compte Rendu : Étude des Peintres selon Roger de Piles

October 26, 2024

Introduction

Ce compte rendu présente les résultats et les démarches suivies lors du travail pratique portant sur la manipulation d'un data frame de peintres, obtenu depuis la bibliothèque `mass` en R. L'objectif principal de ce TP est de comprendre comment utiliser R pour appliquer les connaissances acquises en statistiques, en mettant l'accent sur l'application de lois de probabilité.

Les exercices couverts durant cette séance incluent :

- Le calcul de la moyenne simple et de la variance des données contenues dans le data frame.
- L'estimation de probabilités simples à l'aide des fonctions `dpois`, `pnorm`, et `qf` ...
- La création de fonctions en R pour la densité et la fonction cumulative.
- La génération de graphiques descriptifs, notamment des histogrammes et des courbes, ainsi que l'utilisation de fonctions statistiques pour le calcul de la moyenne et de l'écart-type.

Dans ce compte rendu, nous détaillons les réponses aux questions du TP, en expliquant les étapes suivies pour réaliser chaque tâche, les commandes utilisées dans R et les résultats obtenus.

Réponse

1 Etude de peintres

Q1 En utilisant des histogrammes, visualiser la distribution des notes pour chaque critère.

```
library(MASS)
```

Nous avons importé la bibliothèque MASS, qui utilise la fonction `library` pour charger des paquets et des fonctions supplémentaires. Cette bibliothèque contient un ensemble de données sur des peintres que nous allons utiliser pour nos études.

```
data(painters)
```

Ce code est utilisé pour charger une 'Dataframe' de données appelé `painters` dans notre environnement R

```
head(painters)
```

	Composition	Drawing	Colour	Expression	School
## Da Udine	10	8	16	3	A
## Da Vinci	15	16	4	14	A
## Del Piombo	8	13	16	7	A
## Del Sarto	12	16	9	8	A
## Fr. Penni	0	15	8	0	A
## Giulio Romano	15	16	4	14	A

Nous avons utilisé cette ligne de code pour avoir une idée de la structure de notre data frame. Nous pouvons voir que notre data frame comporte 5 colonnes. Nous pouvons voir dans la fenêtre

Data		
 painters	54 obs. of 5 variables	





de l'environnement de RStudio que le data frame contient 54 lignes et 5 colonnes.

```
par(mfrow=c(2, 2))
hist(painters$Composition, main = "Composition", xlab = "Values", col = "lightblue")

hist(painters$Drawing, main = "Drawing", xlab = "Values", col = "lightgreen")

hist(painters$Colour, main = "Colour", xlab = "Values", col = "lightcoral")

hist(painters$Expression, main = "Expression", xlab = "Values", col = "lightgoldenrod")
```



Q2 Calculer dans le vecteur moyenne La moyenne des quatre notes pour chaque peintre.

```
moyenne <- (painters$Composition + painters$Drawing + painters$Colour + painters$Expression) / 4
```

Nous avons calculé la moyenne avec une méthode simple, similaire à la moyenne empirique nous avons additionné les valeurs de Composition, Drawing, Colour et Expression pour chaque peintre, puis nous avons divisé le total par 4.

Q3 Calculer la moyenne, la variance et l'écart type empirique en utilisant uniquement la fonction `length()` et `sum()`. Puis retrouvez ces valeurs avec les fonctions `mean()`, `sd()` et `var()`.

```
M<-sum(moyenne)/length(moyenne)
identical(M,mean(moyenne))

## [1] TRUE
```

À partir du TRUE obtenu de l'opération logique `M == moyenne`, nous avons obtenu le même résultat que la fonction `mean()`.

```
var<-(sum(moyenne**2-M**2))/(length(moyenne))

V<-sd(moyenne)**2
```

Nous avons calculé la variance en utilisant la formule empirique de variance :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Nous avons ensuite comparé cette variance à celle calculée par la fonction `sd()`, qui est l'écart type (σ). La variance est égale au carré de l'écart type :

$$\sigma^2 = (\text{sd}())^2$$

```
identical(var,V)

## [1] FALSE
```

Comme nous pouvons le voir, ces deux valeurs ne sont pas égales, et cela est dû au fait que RStudio calcule la variance en utilisant la formule de la variance corrigée $S_n'^2$, qui est l'estimateur sans biais de la variance.

$$S_n'^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

```
varC<-(sum(moyenne**2-M**2))/(length(moyenne)-1)
identical(varC,V)


## [1] FALSE
```

Comme nous pouvons le voir, la fonction d'égalité stricte retourne toujours FALSE, mais cette fois-ci parce qu'elle vérifie si les deux valeurs sont 100% identiques. Comme vous pouvez le voir sur l'image ci-dessous, l'erreur est de l'ordre de 10^{-14} . Cette erreur est due au fait que RStudio calcule l'écart type en utilisant la variance corrigée, puis prend la racine carrée, puis, nous avons élevé au carré, ce qui a généré cette petite erreur.

v	6.28843466107617
varC	6.28843466107619

Histogram

```
hist(moyenne, main = "Moyenne", xlab = "Values", col = "lightpink")
```



Nous pouvons voir que la moyenne des moyennes se situe dans l'intervalle [10,12].

2 Calcul de probabilités

Introduction à la calcul des probabilités avec RStudio

Dans RStudio, le calcul des probabilités repose sur l'utilisation de différentes fonctions associées aux lois de probabilité. Ces fonctions suivent une nomenclature commune qui facilite leur utilisation :

- **dXXX** : Représente la fonction de densité pour les lois continues, ou la fonction de masse pour les lois discrètes. Ici, XXX correspond à un raccourci pour une loi de probabilité spécifique. Par exemple, `dnorm()` pour la loi normale, `dpois()` pour la loi de Poisson, etc.
- **pXXX** : Correspond à la fonction de répartition cumulative, ou fonction de distribution cumulative (CDF). `pXXX` renvoie la probabilité que la variable aléatoire soit inférieure ou égale à une certaine valeur. Par exemple, `pnorm()` pour la loi normale, ou `ppois()` pour la loi de Poisson.
- **qXXX** : Permet de calculer le fractile (ou quantile) d'une distribution. La fonction `qXXX` agit comme une méthode "inverse" de la fonction de répartition cumulative : pour une probabilité donnée p , elle retourne la valeur pour laquelle la variable aléatoire atteint ou dépasse cette probabilité. Par exemple, `qnorm()` pour la loi normale, ou `qf()` pour la loi de Fisher.

Q5 Calculer les probabilités des événements suivants:

Pour calculer la probabilité, nous utiliserons à la fois les fonctions `pXXX()` et `dXXX()`.

1. une variable normale centrée réduite est supérieure à -2.

pour cette question Nous utiliserons la fonction `qnorm(Valeur, espérance( $\mu$ ), écart_type( $\sigma$ ))`. Dans ce cas si une variable suit une loi normale centrée réduite, notée $Z \sim \mathcal{N}(0, 1)$, alors son espérance est égale à 0 car elle est centrée, et son écart-type est égal à 1 car elle est réduite.

$$P(Z > -2) = 1 - P(Z \leq -2) = 1 - \text{pnorm}(-2, 0, 1)$$

```
1-pnorm(-2,0,1)
```

```
## [1] 0.9772499
```

2. Une variable normale d'espérance 35 et d'écart type 3 est inférieure à 39.

$$\mu = 35$$

$$\sigma = 3$$

$$P(X < 39) = \text{pnorm}(39, 35, 3)$$

```
pnorm(39,35,3)
```

```
## [1] 0.9087888
```

3. Une variable normale d'espérance 35 et d'écart type 3 est entre 37 et 53.

$$\mu = 35$$

$$\sigma = 3$$

Nous devons calculer la probabilité que la variable soit dans l'intervalle $[37, 53]$. Cela correspond à l'aire dans cet intervalle. Nous allons donc calculer la probabilité dans l'intervalle $[-\infty, 53]$ moins la probabilité dans l'intervalle $[-\infty, 37]$. Ainsi, nous avons :

$$P(37 < X < 53) = P(X < 53) - P(X < 37)$$

Pour une variable normale Z suivant la loi normale $\mathcal{N}(35, 3)$, nous avons :

$$P(37 < X < 53) = \text{pnorm}(53, 35, 3) - \text{pnorm}(37, 35, 3)$$

```
pnorm(53,35,3)-pnorm(37,35,3)
```

```
## [1] 0.2524925
```

4. Obtenir 9 piles sur 15 lancers d'une pièce de monnaie équilibrée.

La pièce est équilibrée, ce qui indique que la probabilité d'obtenir une pile est de $\frac{1}{2}$ et celle d'obtenir une face est également de $\frac{1}{2}$.

Nous avons $n = 15$ comme nombre de lancers et $k = 9$ comme nombre de piles. Nous définissons $X = 1$ si c'est une pile et $X = 0$ si c'est une face, ce qui nous donne une loi binomiale.

Pour cette question, nous utiliserons la fonction de masse, notée dans R comme `dbinom`.

$$\text{dbinom}(n, k, 0.5)$$

```
dbinom(9,15,0.5)
```

```
## [1] 0.1527405
```

5. Obtenir plus de 9 piles sur 15 lancers de la même pièce de monnaie.

$$P(X > 9) = 1 - P(X \leq 9) = 1 - (P_0 + P_1 + \dots + P_9)$$
$$n = 15, k = 9, p = 0.5$$

```
1 - pbinom(9, 15, 0.5)
```

```
## [1] 0.1508789
```

6. Obtenir au moins 9 piles sur les 15 lancers.

$$P(X \geq 9) = 1 - P(X < 9) = 1 - (P_0 + P_1 + \dots + P_8)$$

```
1-pbinom(9-1,15,0.5)
```

```
## [1] 0.3036194
```

7. Obtenir entre 9 et 13 piles sur 20 lancers d'une pièce telle que $p = 0.8$.

```
pbinom(13,20,0.8)- pbinom(9,20,0.8)
```

```
## [1] 0.0861291
```

Q6 trouvez les fractiles d'ordre $\alpha = 0.05, 0.1, 0.9$ pour les lois suivantes :

Dans cette partie, nous utiliserons `qxxx()` afin de trouver les fractiles d'un certain ordre.

```
alpha<-c(0.05,0.1,0.9)
```

1. Loi normale centrée réduite.

```
qnorm(alpha)
```

```
## [1] -1.644854 -1.281552 1.281552
```

2. Loi du χ^2 à 10 degrés de liberté.

```
qchisq(alpha,df=10)
```

```
## [1] 3.940299 4.865182 15.987179
```

3. Loi de Student à 5 degrés de liberté.

```
qt(alpha,df=5)
```

```
## [1] -2.015048 -1.475884 1.475884
```

4. Loi de Fisher à 2 et 5 degrés de liberté.

```
qf(alpha, 2, 5)
```

```
## [1] 0.05182311 0.10761220 3.77971608
```

3 Implémentation d'une loi de probabilité

Q7 Écrire la fonction $dloi(x, b)$ qui donne, pour tout $x \in \mathbb{R}$, son image par la densité $f(x)$ de la loi $\mathcal{L}(b)$.

On a :

$$f(x) = \begin{cases} \frac{2}{b^2}x & \text{si } 0 \leq x \leq b \\ 0 & \text{sinon} \end{cases}$$

avec $b > 0$. On notera cette loi

$\mathcal{L}(b)$. Nous avons une fonction qui a deux inconnues x et b définie dans l'intervalle $0 < x < b$ pour

créer une fonction en R qui a deux entrées dans ce cas x et b . Nous appelons cette loi "d" pour densité, et nous savons que sa densité est caractérisée par deux propriétés : elle est positive et son intégrale égal 1, quelle que soit la valeur de $b > 0$, est égale à un, comme le prouve l'équation (3).

```
x<-0
```

```
dloi<-function(x,b){  
  y<-2/b**2*x  
  y[x>b | x<0]<-0  
  return(y)  
}
```

Comme vous pouvez le voir dans la fonction de densité, la première ligne est la fonction de densité et la deuxième ligne est là pour vérifier que vous êtes dans le domaine de définition en écrasant la première valeur à l'intérieur du vecteur avec 0 si elle n'est pas dans le domaine de définition.

Q8 calculer la densité au point $x = -1, 0, 1, 2, 3, 4, 5$ de la variable aléatoire qui suit la loi $\mathcal{L}(3)$.

```
x<-c(-1,0,1,2,3,4,5)  
dloi(x,3)
```

```
## [1] 0.0000000 0.0000000 0.2222222 0.4444444 0.6666667 0.0000000 0.0000000
```

Nous devons simplement insérer le vecteur x et la valeur de b à l'intérieur de la fonction $dloi()$.

Q9 écrire la fonction $ploi(x, b)$ qui donne la fonction de répartition de loi $\mathcal{L}(b)$.

Nous avons calculé la fonction de répartition de la fonction `dloi()` analytiquement prouvé dans (3), Car si nous le calculons en utilisant la fonction intégrée `integrate()`, nous obtenons une approximation et non la valeur réelle, car R utilise des méthodes numériques pour calculer les intégrales. :

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^2}{b^2} & \text{si } 0 \leq x \leq b \\ 1 & \text{si } x > b \end{cases}$$



Nous devons maintenant traduire cela en code R.

```
ploi<-function(x,b){
  y<-x**2/b**2
  y[x>=b]<-1
  y[x<0]<-0
  return(y)
}
```

Nous avons fait la même chose que pour `dloi()`. Nous avons calculé la première ligne, puis vérifié si $x \geq b$. Dans ce cas, nous écrasons la valeur précédente et la rendons égale à 1. Sinon, nous vérifions si $x < 0$; si cette condition est satisfaite, nous écrasons la valeur et la rendons égale à 0. À la fin, cela retourne un vecteur.

Q10 En fixant $b = 3$, tracer les graphes de $ploi(x, b)$ et de $dloi(x, b)$ entre -5 et 5 , en utilisant la fonction `curve()`.

```
b=3
par(mfrow=c(1,2))
curve(dloi(x,b),from = -5,to=5)
curve(ploi(x,b),from = -5,to=5)
```



Nous pouvons voir que `dloi()` est strictement croissante.

Q11 Écrire la fonction $qloi(\alpha, b)$ qui retourne le fractile d'ordre α de la loi $\mathcal{L}(b)$. On admettra que le fractile d'ordre 0 est égal à 0 et celui d'ordre 1 est égal à b .

```
qloi<-function(alpha,b){  
  x<-sqrt(alpha*b**2)  
  x[alpha=1]<-b  
  x[alpha=0]<-0  
  return(x)  
}
```

C'est assez simple, c'est une fonction inverse, Le support du $\mathcal{L}(b)$ c'est $[0, b]$, Alors si la probabilité α est égale à 0, elle prend la plus petite valeur du support, qui dans ce cas est 0, Si la probabilité α est égale à 1, elle prend la plus grande valeur du support, qui dans ce cas est b .

Q12 Démontrer que la variable $Y = F_X^{-1}(X)$ suit la loi $\mathcal{L}(b)$ avec X suivant $U[0, 1]$. Puis, écrire la fonction $rloi(n, b)$ qui génère un échantillon aléatoire de taille n de la loi $\mathcal{L}(b)$.

Dans ce cas, nous utilisons la méthode de l'inverse. Pourquoi pouvons-nous utiliser la méthode de l'inverse ?

Nous pouvons l'utiliser ici car la fonction de répartition est bijective, ce que nous savons grâce à la densité de la fonction qui est strictement croissante et continue. Cela garantit qu'il y a une bijection. Et nous avons utilisé X suivant une loi uniforme $[0, 1]$ car la probabilité est entre 0 et 1. La question cherche à nous enseigner comment générer un échantillon d'une loi de probabilité.





```
rloi<-function(n,b){  
  x<-runif(n)  
  y<-qloi(x,b)  
  return(y)  
}
```

Nous générons n réalisations de $U[0, 1]$ et nous le faisons entre 0 et 1 parce qu'une probabilité est comprise entre 0 et 1. Nous avons utilisé la fonction inverse $qloi$ que nous avons déjà créée. Maintenant, nous pouvons générer un échantillon de taille n de la loi $\mathcal{L}(b)$. +

Q13 Générer un échantillon de loi $\mathcal{L}(b)$ de taille n ($n = 10, 100, 1000, 10000$). Visualiser les 4 échantillons sous la forme d'histogrammes puis comparer avec la densité.

Et pour nous assurer que notre code R est correct, si la taille de l'échantillon approche l'infini, les réalisations créées par $rloi$ devraient prendre la forme de la densité $\mathcal{L}(b)$.


```
par(mfrow=c(2,2))  
set.seed(7)  
hist(rloi(10,b),freq = FALSE)  
hist(rloi(100,b),freq = FALSE)  
hist(rloi(1000,b),freq = FALSE)  
hist(rloi(10000,b),freq = FALSE)
```



Comme vous pouvez le voir, plus n est grand, plus il se rapproche de notre densité.

```
par(mfrow=c(1,2))
hist(rloi(10000,b),freq = FALSE)
curve(dloi(x,b),from=-5,to=5)
```

Histogram of `rloi(10000, b)`



Et nous remarquons que notre échantillon généré est presque identique à notre densité, ce qui montre que cette méthode est vraiment efficace pour sa simplicité.

Conclusion

Ce compte rendu comporte trois parties :

Étude des peintres

Dans cette partie, nous avons appris comment calculer la moyenne d'un data frame et sa variance.

Calcul de probabilités

Dans cette partie, nous avons appris à calculer certaines probabilités en utilisant diverses fonctions préconstruites qui facilitent grandement le calcul des probabilités. Nous avons également appris à calculer les fractiles d'un ordre donné.

Implémentation d'une loi de probabilité

Dans cette partie, nous avons appris comment prendre une certaine densité et la traduire en code R. Nous avons appris à créer `ploi`, qui est la fonction de répartition cumulative, `qloi`, qui est la fonction inverse, et `rloi`, qui est une fonction qui génère des échantillons d'une loi donnée de taille `nn`. Tout cela nous a permis de comprendre comment fonctionnent certaines fonctions préconstruites comme `dbinom`, `ppois`, `rexp`, et `qexp`. Nous avons également appris à appliquer la méthode de l'inversion, où la fonction cumulative doit être bijective.

Cette expérience m'a permis de renforcer mes compétences en R et en statistiques, ce qui sera essentiel pour mes futures analyses de données. Je suis convaincu que ces connaissances me seront précieuses dans mes études et ma carrière en analyse de données.

Annexe

$$\begin{aligned}\int_{-\infty}^{\infty} f(x) \, dx &= \int_0^b \frac{2}{b^2} x \, dx \\ \int_0^b \frac{2}{b^2} x \, dx &= \frac{2}{b^2} \int_0^b x \, dx = \frac{2}{b^2} \left[\frac{x^2}{2} \right]_0^b = \frac{2}{b^2} \cdot \frac{b^2}{2} = 1 \\ F(x) &= \int_{-\infty}^x f(t) \, dt\end{aligned}$$

$x < 0$:

$$F(x) = 0$$

$0 \leq x \leq b$:

$$\begin{aligned}F(x) &= \int_0^x \frac{2}{b^2} t \, dt \\ &= \frac{2}{b^2} \int_0^x t \, dt \\ &= \frac{2}{b^2} \left[\frac{t^2}{2} \right]_0^x \\ &= \frac{2}{b^2} \cdot \frac{x^2}{2} = \frac{x^2}{b^2}\end{aligned}$$

$x > b$:

$$\begin{aligned}F(x) &= \int_0^b \frac{2}{b^2} t \, dt \\ &= \frac{2}{b^2} \int_0^b t \, dt \\ &= \frac{2}{b^2} \left[\frac{t^2}{2} \right]_0^b \\ &= \frac{2}{b^2} \cdot \frac{b^2}{2} = 1\end{aligned}$$